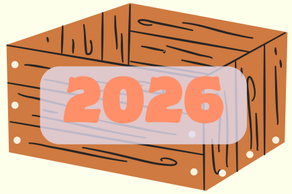
FRESH LOCAL NATURE



BIGMART SALES DATA



By Muhammad Alfi Syahputra



FRESH LOCAL NATURE

FROM FARM TO TABLE

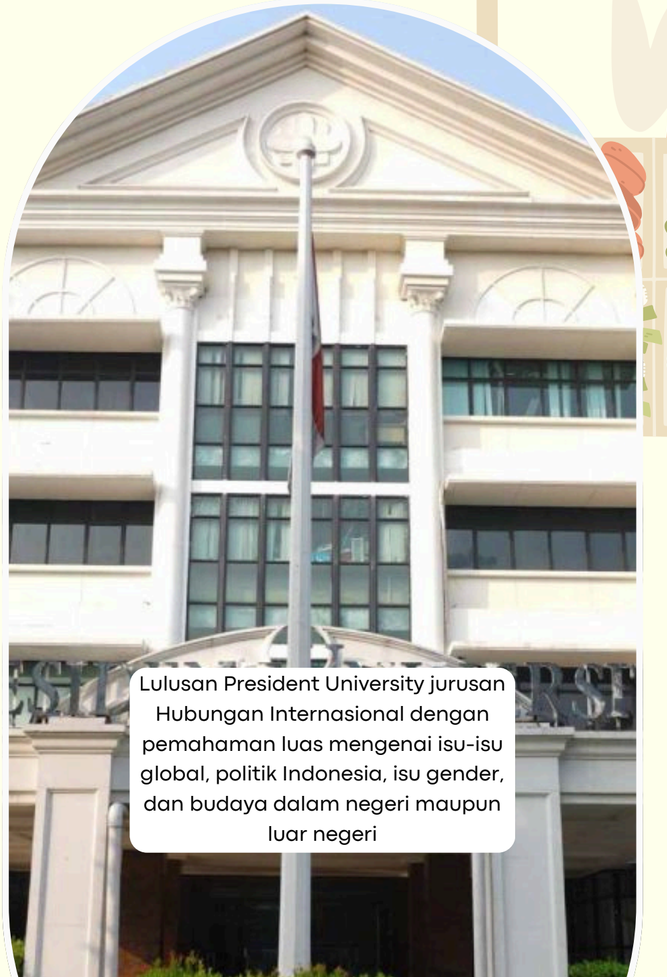
INTRODUCTION



Memiliki pengalaman internship sebagai staff hubungan Masyarakat dan juga mengelola akun social media untuk Dinas Kesehatan Kota Bandung selama 6 bulan

MUHAMMAD ALFI SYAHPUTRA
saya merupakan orang yang memiliki motivasi dan inisiatif tinggi, serta rasaingin terus mengembangkan keahlian dan kemampuan profesionalnya. Bidangminat: Hubungan Luar Negeri, HubunganMasyarakat, dan Sumber Daya Manusia. Dan sekarang ditambah Data Analyst



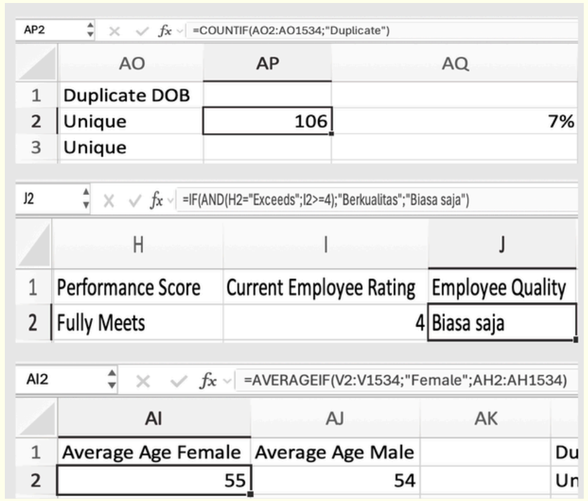


Lulusan President University jurusan Hubungan Internasional dengan pemahaman luas mengenai isu-isu global, politik Indonesia, isu gender, dan budaya dalam negeri maupun luar negeri



HEALTHY CHOICES HAPPY FAMILY

PROJECT





Menganalisa dampak dari terjadinya fenomena turnover pada suatu perusahaan dan juga faktor-faktor lain yang menyebabkan tingginya fenomena turnover tersebut

PRESIDENT UNIVERSITY

E-PORT
EDUCATION SUPPORT

SOCIAL PROJECT REPORT

E-PORT (EDUCATION SUPPORT)





Sosialisasi pentingnya belajar bahasa inggris dan juga membangun minat baca yang tinggi

PROJECT- PROJECT - PROJECT

EAT FRESH STAY HEALTHY

PENTINGNYA ANALISIS DATA PENJUALAN BAGI BISNIS





BigSeller

Fitur Pelanggan Sumber Daya Harga Tentang Kami English ketik dan Tekan Ente

Daftar Isi

Apa Itu Data Penjualan?

Mengapa Analisis Data Penjualan

1. Mengidentifikasi peluang dan prospek bisnis

Data penjualan membantu bisnis mengetahui produk yang paling diminati, periode penjualan tertinggi, hingga tren yang sedang berkembang. Dari sini, Anda dapat menentukan peluang ekspansi produk atau pasar baru.

MAJOO CARE 0811 500 460 DISKON 50% SEMUA PAKET MAJOO

ma7oo UPMARKET | UPSCALE | UPWARD

Produk Layanan Solusi Custom Harga

1. Sebagai penentu arah kebijakan

Data penjualan berperan penting dalam penentuan arah kebijakan perusahaan karena berisi fakta di lapangan. Data penjualan yang valid akan menghasilkan informasi yang akurat pula.

2. Sebagai bahan evaluasi

Dari data penjualan, perusahaan bisa melakukan analisis untuk mengevaluasi jalannya bisnis, sekaligus untuk mengekstraksi informasi yang berguna bagi pengembangan perusahaan. Data penjualan dapat berisi tren pasar dan kebiasaan pelanggan yang kerap berubah. Sehingga, pelaku usaha dapat memahami langkah-langkah strategis untuk pengembangan usaha.

3. Sebagai database

Data penjualan yang terkumpul dapat menjadi sumber database, sehingga dapat sewaktu-waktu diperiksa kembali jika terjadi inkonsistensi. Database penjualan yang rapi juga bisa diakses dan digunakan oleh pihak lain yang membutuhkan.

Ompas ENABLING SUCCESS

Services About Us Insights Articles Career Contact Us

Jika Anda memahami contoh data penjualan beserta penerapannya, berikut beberapa manfaat yang akan Anda peroleh.

1. Bahan acuan dalam penetapan kebijakan

Data penjualan membantu para pelaku usaha untuk melihat sejauh mana perkembangan bisnisnya. Melalui data tersebut, Anda dapat menganalisis usaha tersebut sedang naik atau turun. Dengan menganalisis conto data penjualan yang ada di perusahaan, Anda dapat menjadikannya acuan untuk menetapkan kebijakan dalam berbisnis.

2. Sumber database

Data penjualan yang terkumpul akan menjadi sumber database bagi perusahaan. Kumpulan data tersebut merupakan sumber informasi atau bekal bagi perusahaan untuk menjalankan bisnis kedepannya.





EAT FRESH STAY HEALTHY

CHOOSE

FRESH

CHOOSE LOCAL

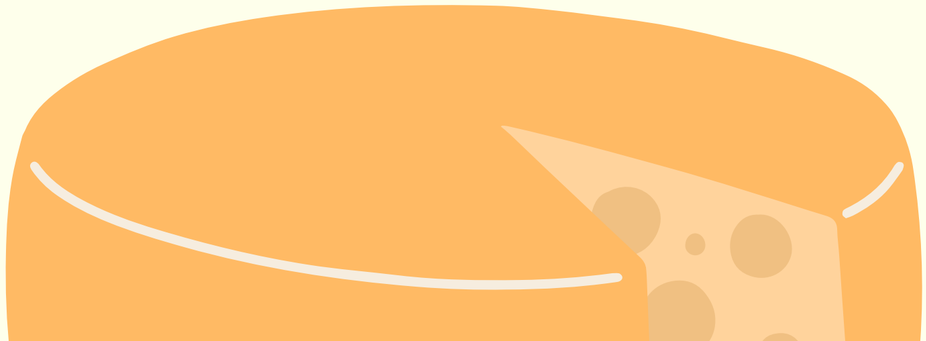
PROBLEM STATEMENT

DATA UNDERSTANDING

DATA PREPARATION

VISUALIZATION OUTPUT

CONCLUSION & RECOMMENDATIONS



GOOD FOR YOU

GOOD FOR

PLANET

PROBLEM STATEMENT

Apakah harga mempengaruhi terhadap penjualan produk tersebut?

Wilayah mana yang memiliki kontribusi tinggi terhadap penjualan?

Apakah kandungan dalam suatu produk mempunyai pengaruh terhadap penjualan?



GOOD FOR YOU

GOOD FOR

HEALTHY CHOICES HAPPY FAMILY

DATA UNDERSTANDING

	Item_Identifier	Item_Weight	Item_Fat_Content	Item_Visibility	Item_Type	Item_MRP	Outlet_Identifier	Outlet_Establishment_Year	Outlet_Size	Outlet_Location_Type	Outlet_Type	Item_Outlet_Sales
0	FDA15	9.300	Low Fat	0.016047	Dairy	249.8092	OUT049	1999	Medium	Tier 1	Supermarket Type1	3735.1380
1	DRC01	5.920	Regular	0.019278	Soft Drinks	48.2692	OUT018	2009	Medium	Tier 3	Supermarket Type2	443.4228
2	FDN15	17.500	Low Fat	0.016760	Meat	141.6180	OUT049	1999	Medium	Tier 1	Supermarket Type1	2097.2700
3	FDX07	19.200	Regular	0.000000	Fruits and Vegetables	182.0950	OUT010	1998	NaN	Tier 3	Grocery Store	732.3800
4	NCD19	8.930	Low Fat	0.000000	Household	53.8614	OUT013	1987				

Dataset memiliki dimensi :

Jumlah Baris = 8523

Jumlah Kolom = 12

```
data = pd.read_csv("BigMart Sales Data.csv")
```

Sumber data:
https://www.kaggle.com/datasets/ahmadrezagholami2001/bigmart-sales-dataset



COLUMN DESCRIPTION

Column	Deskripsi
Item_Identifier	Kode unik yang digunakan untuk mengidentifikasi setiap produk/barang yang dijual.
Item_Weight	Berat produk dalam satuan berat tertentu. Kolom ini menunjukkan seberapa berat masing-masing produk.
Item_Fat_Content	Kategori kandungan lemak pada produk, misalnya **Low Fat** atau **Regular**.
Item_Visibility	Persentase atau proporsi visibilitas produk di dalam outlet. Nilai yang lebih tinggi menunjukkan produk memiliki tingkat visibilitas yang lebih besar.
Item_Type	Jenis atau kategori produk yang dijual, seperti **Dairy, Soft Drinks, Meat, Household, Fruits and Vegetables**, dan lainnya.
Item_MRP	**Maximum Retail Price**, yaitu harga eceran maksimum produk sebelum mempertimbangkan faktor lainnya.
Outlet_Identifier	Kode unik yang digunakan untuk mengidentifikasi masing-masing outlet/toko.
Outlet_Establishment_Year	Tahun ketika outlet didirikan atau mulai beroperasi.
Outlet_Size	Ukuran outlet, yang dikategorikan menjadi **Small, Medium,** atau **High**.
Outlet_Location_Type	Kategori lokasi outlet berdasarkan tingkat wilayah, yaitu **Tier 1, Tier 2,** atau **Tier 3**.
Outlet_Type	Jenis outlet berdasarkan format atau tipe tokonya, seperti **Grocery Store, Supermarket Type1, Supermarket Type2,** dan **Supermarket Type3**.
Item_Outlet_Sales	Jumlah penjualan produk pada outlet tertentu. Kolom ini biasanya digunakan sebagai **target/dependent variable** untuk menganalisis atau memprediksi penjualan.

DATA TYPE

```
bigmart.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 8523 entries, 0 to 8522
Data columns (total 12 columns):
```

info () bertujuan untuk mengetahui tipe data pada setiap kolomnya.

#	Column	Non-Null Count	Dtype
0	Item_Identifier	8523 non-null	str
1	Item_Weight	7060 non-null	float64
2	Item_Fat_Content	8523 non-null	str
3	Item_Visibility	8523 non-null	float64
4	Item_Type	8523 non-null	str
5	Item_MRP	8523 non-null	float64
6	Outlet_Identifier	8523 non-null	str
7	Outlet_Establishment_Year	8523 non-null	int64
8	Outlet_Size	6113 non-null	str
9	Outlet_Location_Type	8523 non-null	str
10	Outlet_Type	8523 non-null	str
11	Item_Outlet_Sales	8523 non-null	float64

Tipe data untuk kolom Outlet_Establishment_Year yang nantinya juga akan diubah kedalam bentuk datetime

bisa kita lihat pada kolom (Item_Weight & Outlet_Size) terdapat missing value



HEALTHY CHOICES HAPPY FAMILY

DESCRIPTIVE STATISTIC

	Item_Weight	Item_Visibility	Item_MRP	Outlet_Establishment_Year	Item_Outlet_Sales
count	7060.00	8523.00	8523.00	8523.00	8523.00
mean	12.86	0.07	140.99	1997.83	2181.29
std	4.64	0.05	62.28	8.37	1706.50
min	4.56	0.00	31.29	1985.00	33.29
25%	8.77	0.03	93.83	1987.00	834.25
50%	12.60	0.05	143.01	1999.00	1794.33
75%	16.85	0.09	185.64	2004.00	3101.30
max	21.35	0.33	266.89	2009.00	13086.96

Item_Weight, nilai mean dan median nya tidak terlalu berbeda maka simetris

Item_Visibility, nilai mean lebih besar dari median maka sedikit miring ke kanan karena nilainya tidak jauh berbeda

Item_MRP, nilai mean lebih kecil dari nilai mediannya maka sedikit miring kiri karena nilainya tidak jauh berbeda

Outlet_Establishment_Year,nilai standar deviasi nya 8.37 menunjukan bahwa tahun dalam dataset memiliki penyebaran sekitar 8 tahun dari nilai rata-ratanya yaitu 1997,83

Item_Outlet_Sales, nilai mean lebih besar daripada median maka miring kanan

MISSING VALUE AND DUPLICATE

```
bigmart_clean = pd.DataFrame({
    "data_missing": bigmart.isna().sum(),
    "persentase": (bigmart.isna().mean()*100).round(2)
})

bigmart_clean = bigmart_clean[bigmart_clean["data_missing"]>0]
bigmart_clean
```

	data_missing	persentase
Item_Weight	1463	17.17
Outlet_Size	2410	28.28

```
duplicate_persentase = bigmart.duplicated().mean() * 100

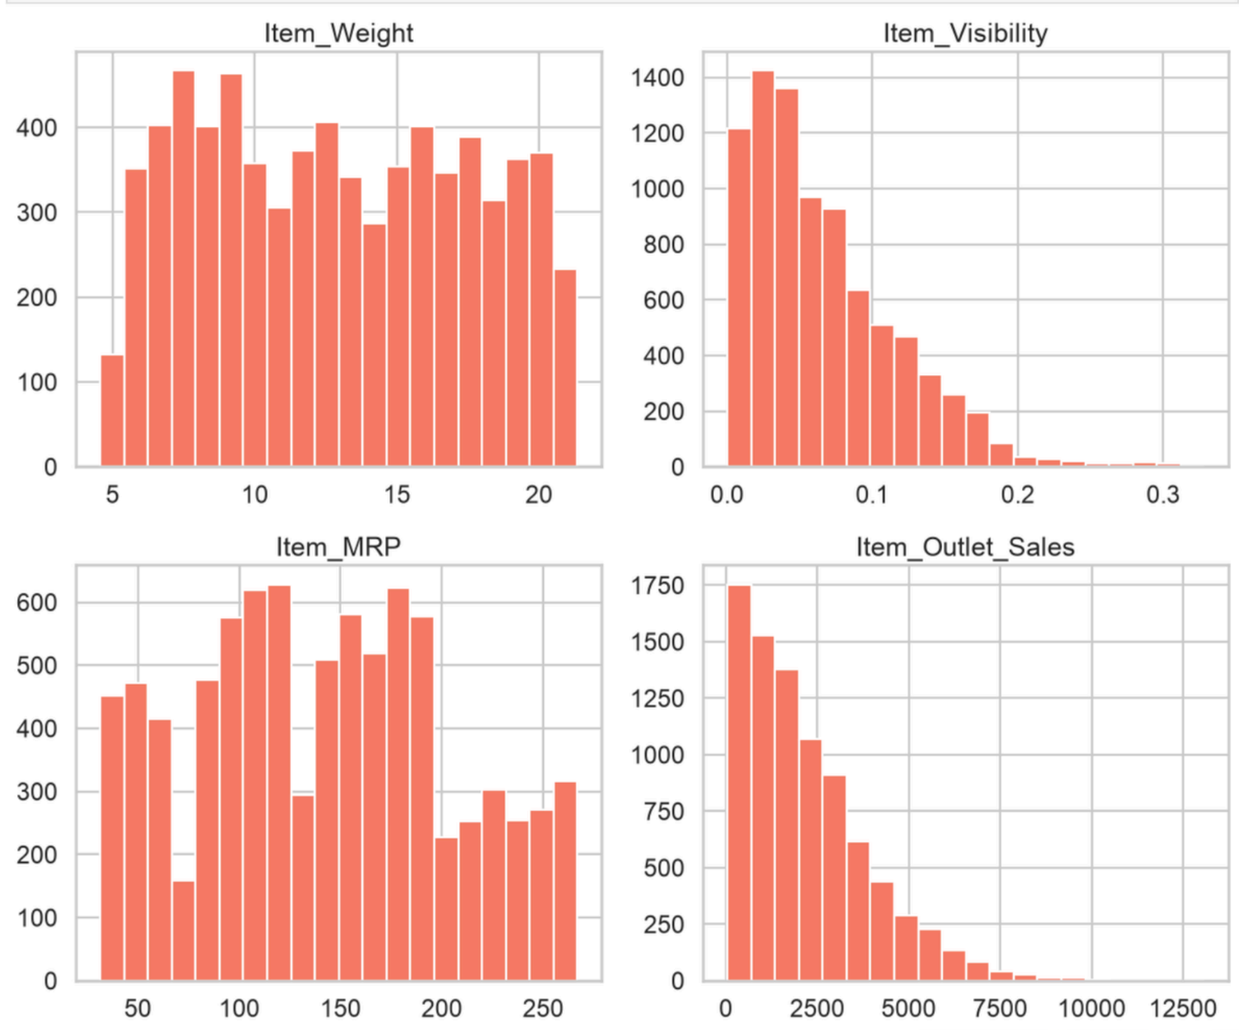
print(f"Persentase duplicate: {duplicate_persentase:.2f}%")
```

```
Persentase duplicate: 0.00%
```

Tidak terdapat duplicate pada data tersebut

HEALTHY CHOICES HAPPY FAMILY

DISTRIBUTION NUMERICAL COLUMN



Item_Weight terdistribusi uniform

Item_MRP terdistribusi non-simetris

Item_Visibility & Item_Outlet_Sales terdistribusi right-skewed atau miring kanan

EARLY INSIGHT

Insight dari data exploration yang bisa disimpulkan yaitu, dataset memiliki variabel numerik dan kategorikal, ditemukannya missing value pada kolom Item_Weight dan Outlet_Size yang perlu ditangani pada saat data cleaning, pada kolom Outlet_Establishment_Year juga perlu dibuah tipe datanya supaya menjadi format datetime agar lebih sesuai dan bukan integer.

DATA PREPARATION

```
bigmart_copy["Item_Fat_Content"].unique()
```

```
<ArrowStringArray>
['Low Fat', 'Regular', 'low fat', 'LF', 'reg']
Length: 5, dtype: str
```

Terdapat inkonsistensi pada penulisan di kolom Item fat content

```
bigmart_copy["Item_Fat_Content"] = bigmart_copy["Item_Fat_Content"].replace(
    {"LF": "Low Fat",
     "low fat": "Low Fat",
     "reg": "Regular",
     "regular": "Regular"}
)
bigmart_copy
```

memastikan data teks memiliki format yang konsisten, sehingga lebih mudah diolah, dianalisis, dan tidak dianggap sebagai kategori yang berbeda padahal memiliki arti yang sama.

Penanganan untuk missing value

```
bigmart_copy["Item_Weight"] = bigmart_copy["Item_Weight"].fillna(
    bigmart_copy["Item_Weight"].median()
)
```

```
bigmart_copy["Outlet_Size"] = bigmart_copy["Outlet_Size"].fillna(
    bigmart_copy["Outlet_Size"].mode()[0]
)
bigmart_copy["Outlet_Size"].value_counts()
```

Penanganan untuk mengubah tipe data dari integer menjadi datetime

```
bigmart_copy["Outlet_Establishment_Year"] = pd.to_datetime(
    bigmart_copy["Outlet_Establishment_Year"],
    format="%Y"
)
bigmart_copy
```

Setelah ditangani

```
7   Outlet_Establishment_Year  8523 non-null   datetime64[us]
```

```python
for i in kolom_outlier :
    Q1 = bigmart_copy[i].quantile(0.25)
    Q3 = bigmart_copy[i].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR
    outlier = (bigmart_copy[i] < lower) | (bigmart_copy[i] > upper)
    jumlah_outlier = outlier.sum()
    persentase_outlier = jumlah_outlier/len(outlier) * 100
    print(f"Jumlah Outlier pada Kolom {i} : {jumlah_outlier}")
    print(f"Persentase Outlier pada Kolom {i} : {persentase_outlier}\n")
```

```
Jumlah Outlier pada Kolom Item_Weight : 0
Persentase Outlier pada Kolom Item_Weight : 0.0

Jumlah Outlier pada Kolom Item_Visibility : 144
Persentase Outlier pada Kolom Item_Visibility : 1.689545934530095

Jumlah Outlier pada Kolom Item_MRP : 0
Persentase Outlier pada Kolom Item_MRP : 0.0

Jumlah Outlier pada Kolom Item_Outlet_Sales : 186
Persentase Outlier pada Kolom Item_Outlet_Sales : 2.1823301654347063
```

Outlier pada kolom Item_Visibility dan Item_Outlet_Sales berhasil ditangani dengan metode Capping

Alasan penanganan menggunakan metode Capping:

Item_Visibility =

- Menghapus data dapat mengurangi jumlah observasi
- Capping mempertahankan seluruh baris data

Item_Outlet_Sales =

- Nilai sales yang sangat tinggi belum tentu merupakan kesalahan
- Produk tertentu memang bisa memiliki penjualan jauh lebih tinggi dibandingkan produk lainnya

```python
Q1_visible = bigmart_copy["Item_Visibility"].quantile(0.25)
Q3_visible = bigmart_copy["Item_Visibility"].quantile(0.75)
IQR_visible = Q3_visible - Q1_visible
lower_visible = Q1_visible - 1.5 * IQR_visible
upper_visible = Q3_visible + 1.5 * IQR_visible

bigmart_copy["Visible_Cap"] = bigmart_copy["Item_Visibility"].clip(lower_visible, upper_visible)
Q1_visible_cap = bigmart_copy["Visible_Cap"].quantile(0.25)
Q3_visible_cap = bigmart_copy["Visible_Cap"].quantile(0.75)
IQR_visible_cap = Q3_visible_cap - Q1_visible_cap
lower_visible_cap = Q1_visible_cap - 1.5 * IQR_visible_cap
upper_visible_cap = Q3_visible_cap + 1.5 * IQR_visible_cap
outlier_visible_cap = (bigmart_copy["Visible_Cap"] < lower_visible_cap) | (bigmart_copy["Visible_Cap"] > upper_visible_cap)
jumlah_outlier_visible_cap = outlier_visible_cap.sum()
persentase_outlier_visible_cap = jumlah_outlier_visible_cap/len(bigmart_copy) * 100
print(f"Jumlah Outlier pada Kolom Visible_Cap : {jumlah_outlier_visible_cap}")
print(f"Persentase Outlier pada Kolom Visible_Cap : {persentase_outlier_visible_cap}")
```

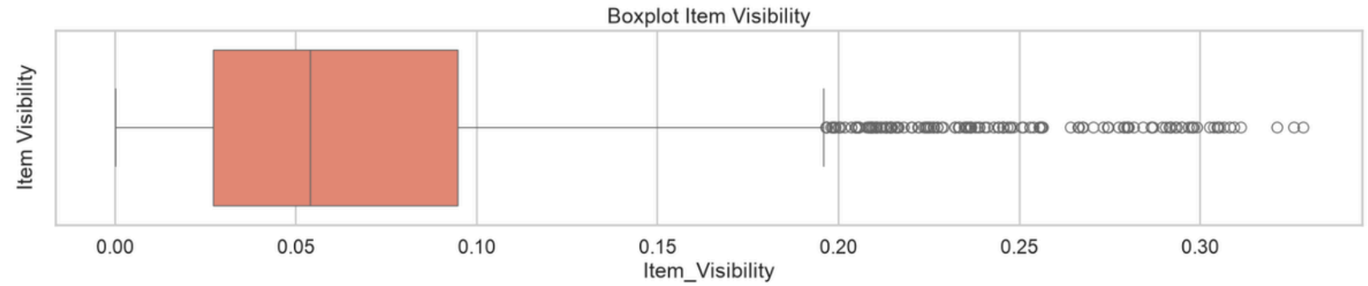
```
Jumlah Outlier pada Kolom Visible_Cap : 0
Persentase Outlier pada Kolom Visible_Cap : 0.0
```

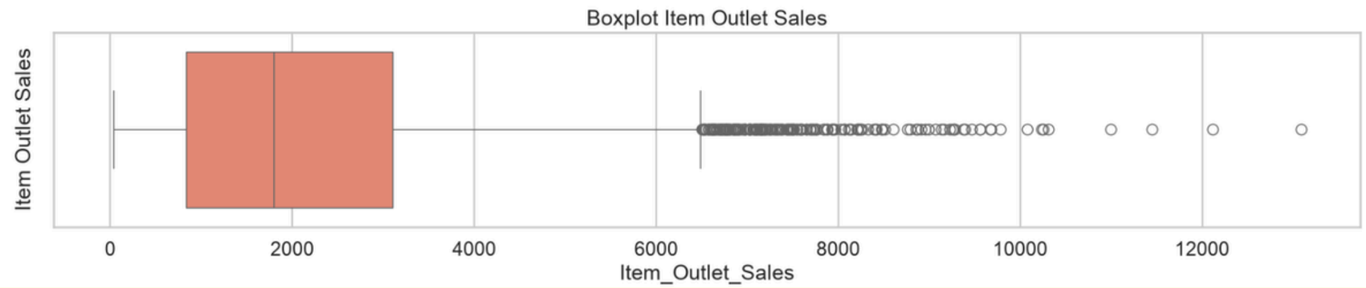
OUTLIER HANDLING

Proses ini bertujuan untuk mengurangi pengaruh nilai ekstrem terhadap hasil analisis dan meningkatkan kualitas data

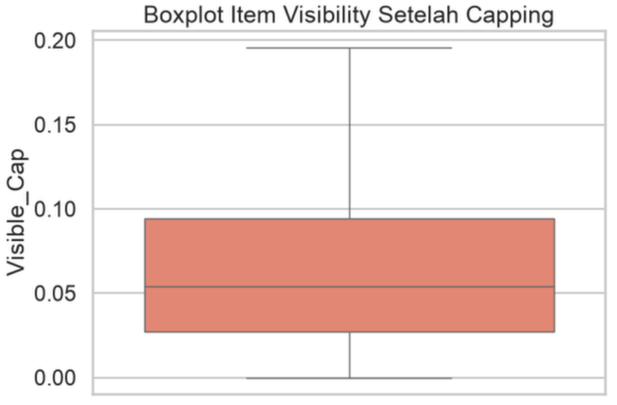
OUTLIER

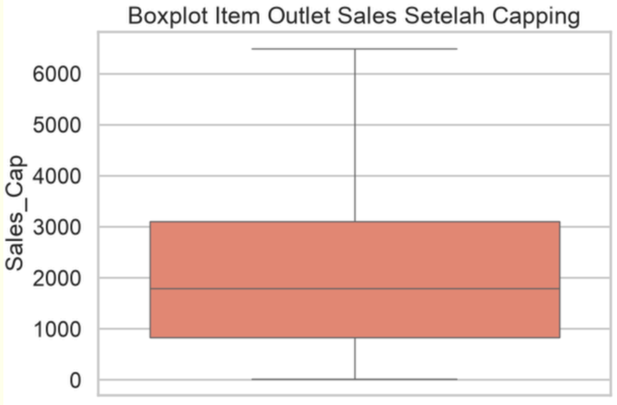
BEFORE





AFTER





ENCODER



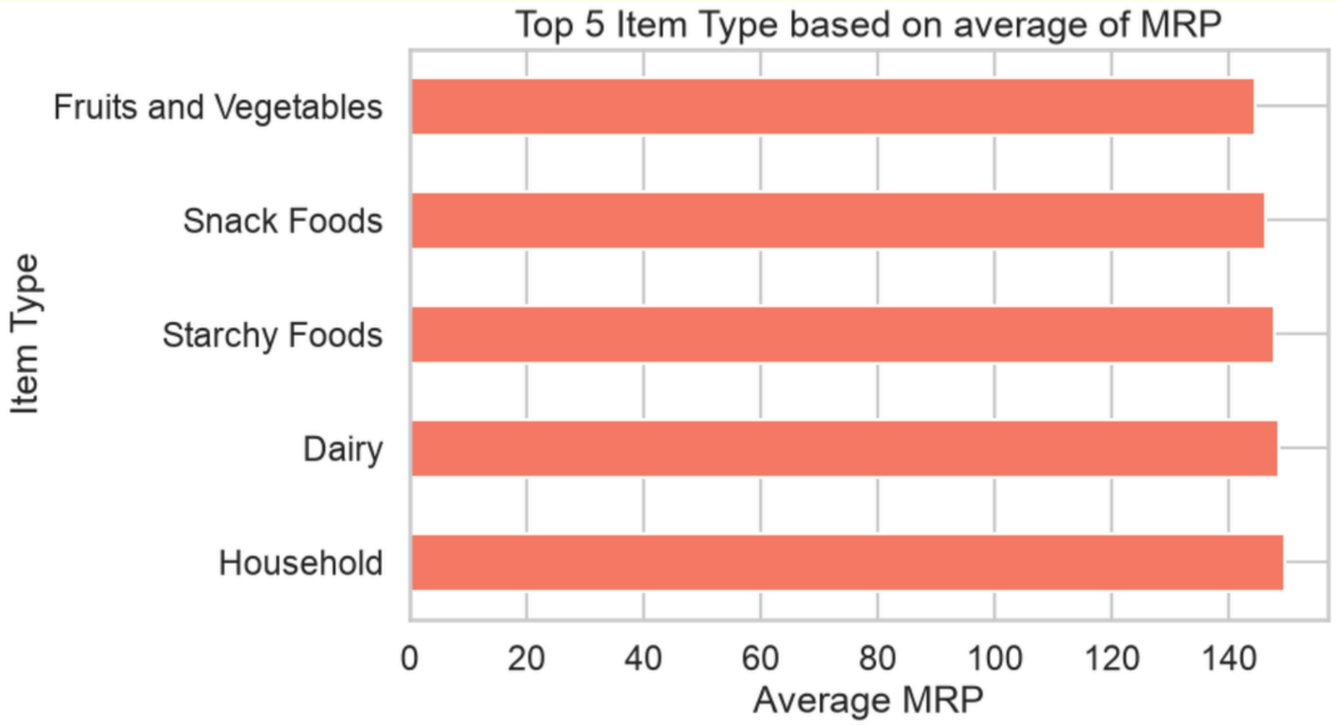

```
bigmart_copy["Item_Identifier_Code"] = le.fit_transform(bigmart_copy["Item_Identifier"])
bigmart_copy["Item_Fat_Code"] = le.fit_transform(bigmart_copy["Item_Fat_Content"])
bigmart_copy["Item_Type_Code"] = le.fit_transform(bigmart_copy["Item_Type"])
bigmart_copy["Outlet_Identifier_Code"] = le.fit_transform(bigmart_copy["Outlet_Identifier"])
bigmart_copy["Outlet_Size_Code"] = le.fit_transform(bigmart_copy["Outlet_Size"])
bigmart_copy["Outlet_Location_Code"] = le.fit_transform(bigmart_copy["Outlet_Location_Type"])
bigmart_copy["Outlet_Type_Code"] = le.fit_transform(bigmart_copy["Outlet_Type"])
```

CHOOSE FRESH CHOOSE LOCAL

VISUALIZATION OUTPUT

```
bigmart_copy.groupby("Item_Type").agg(
    Rata_Rata_MRP=("Item_MRP", "mean"),
    Rata_Rata_Sales=("Item_Outlet_Sales", "mean")
).sort_values(
    by="Rata_Rata_MRP",
    ascending=False
).head(5)
```

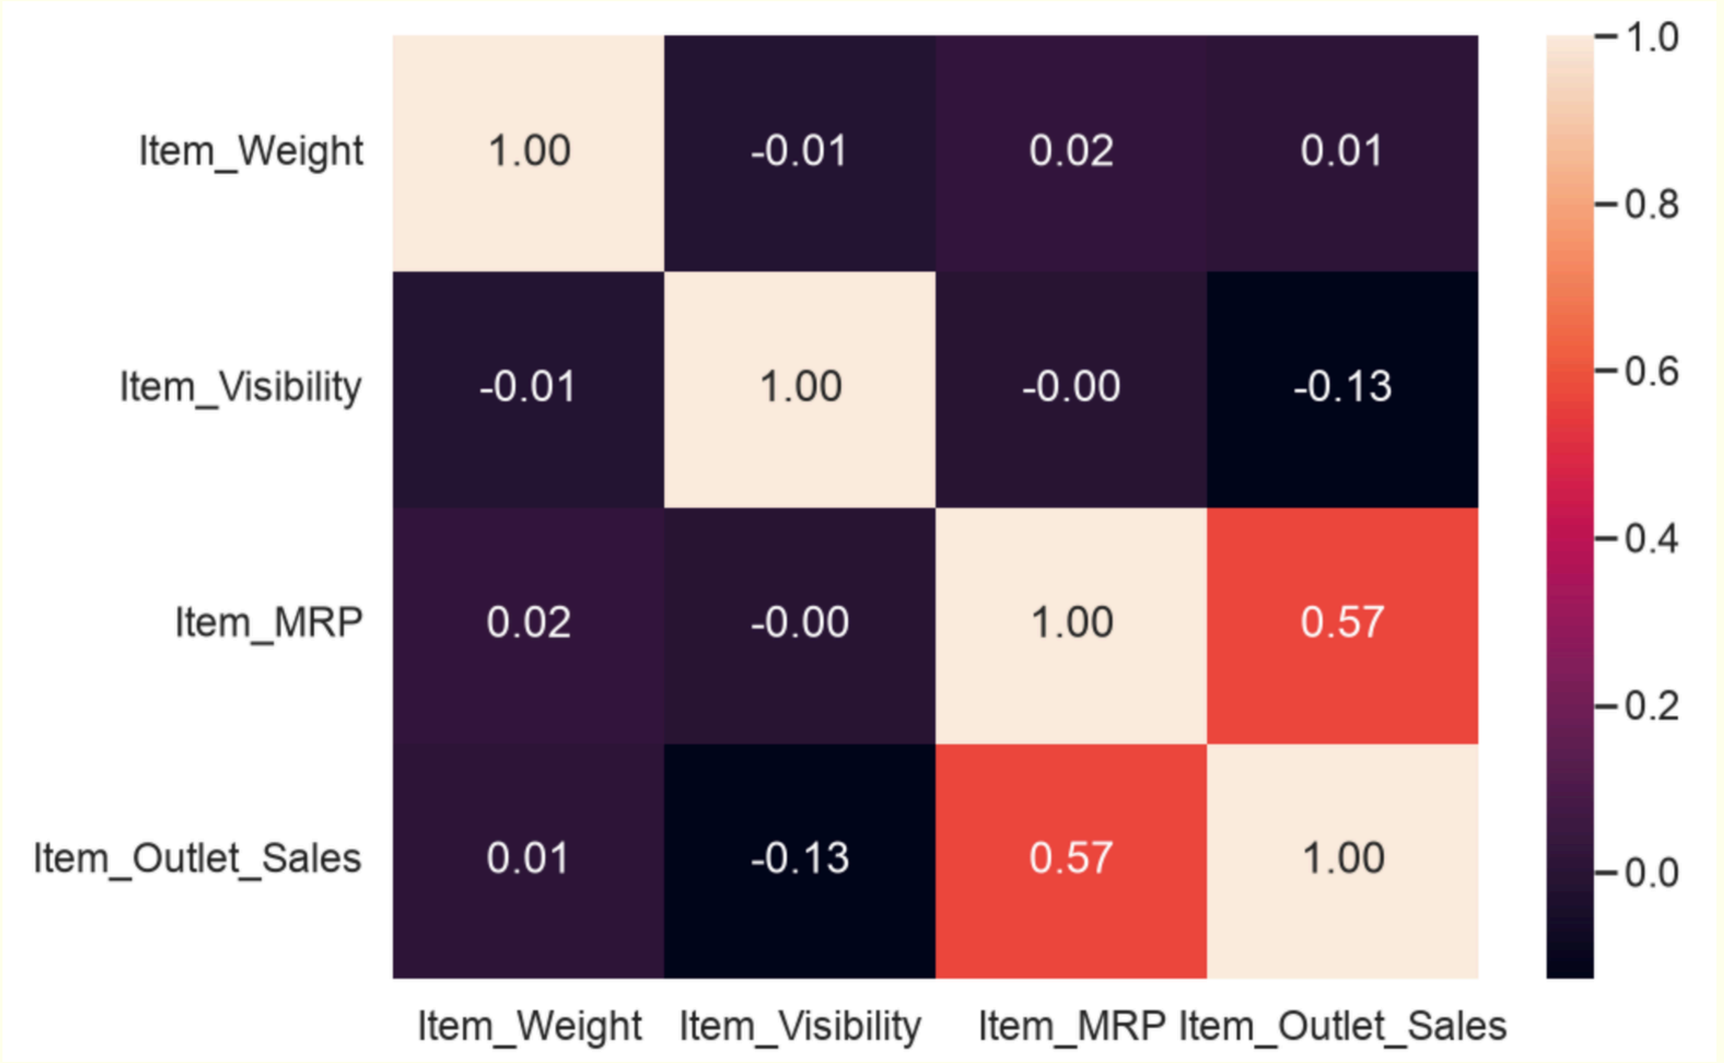
Item_Type	Rata_Rata_MRP	Rata_Rata_Sales
Household	149.424753	2258.784300
Dairy	148.499208	2232.542597
Starchy Foods	147.838023	2374.332773
Snack Foods	146.194934	2277.321739
Fruits and Vegetables	144.581235	2289.009592



Item_Type Household memiliki rata-rata MRP tertinggi, meskipun memiliki harga tertinggi namun hasil penjualan ternyata masih kurang dibanding dengan Item_Type yang lain, maka dari itu strategi harga seperti diskon dan bundling dapat digunakan untuk meningkatkan daya tarik produk dan mendorong penjualan.

CHOOSE

CHOOSE LOCAL



Berdasarkan heatmap tersebut terlihat hubungan yang kuat antara Item_MRP dan juga Item_Outlet_Sales.

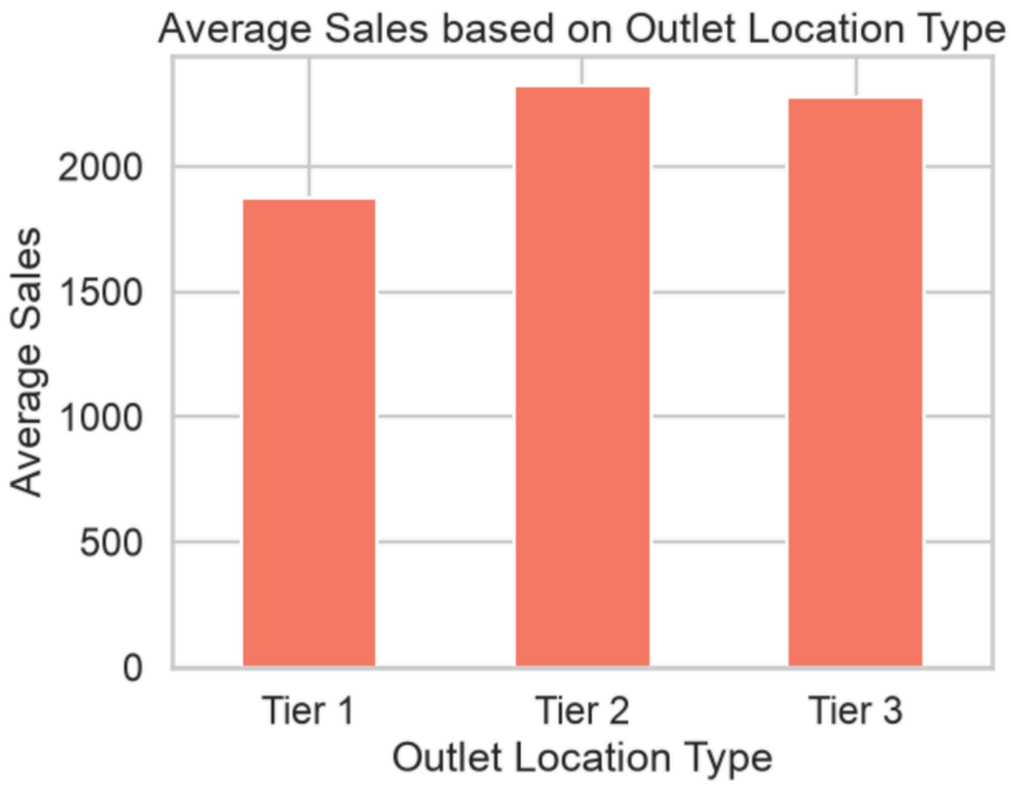
Maka harga barang sangat mempengaruhi untuk hasil penjualan

CHOOSE FRESH CHOOSE LOCAL

VISUALIZATION OUTPUT

```
bigmart_copy.groupby("Outlet_Location_Type")["Item_Outlet_Sales"].agg(["mean"]).rename(
    columns={"mean": "Rata_Rata_Sales"}
).sort_values(
    by="Rata_Rata_Sales",
    ascending=False
)
```

Outlet_Location_Type	Rata_Rata_Sales
Tier 2	2323.990559
Tier 3	2279.627651
Tier 1	1876.909159



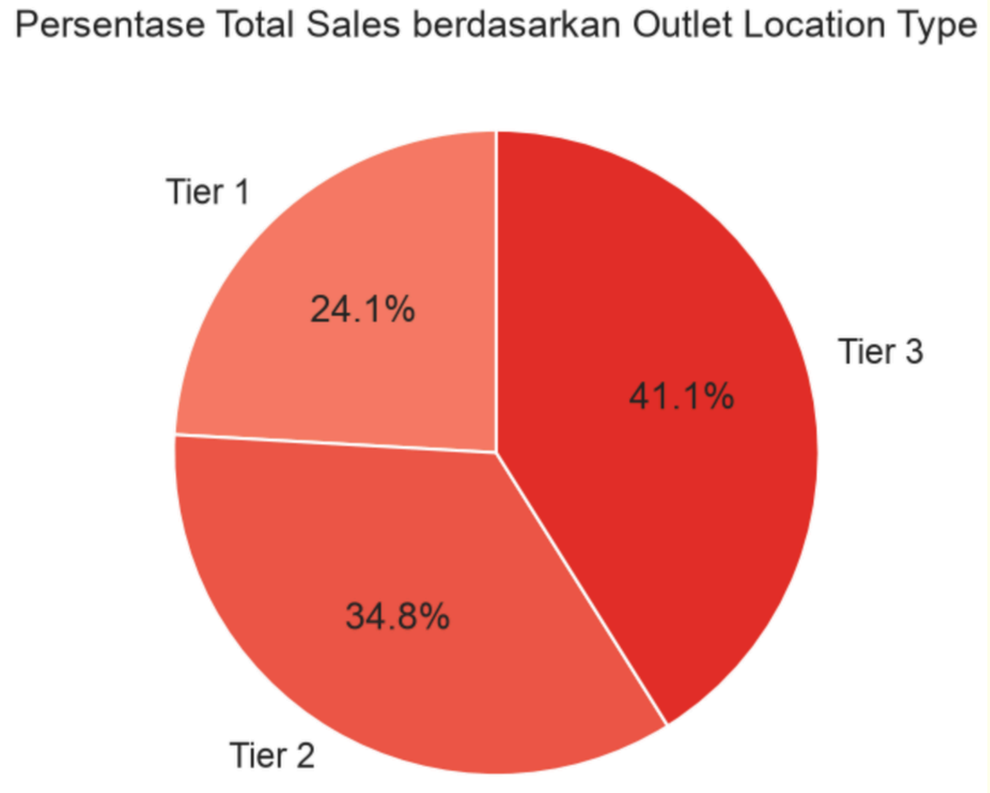
Tier 2 memiliki rata-rata Item_Outlet_Sales tertinggi sebesar 2323.99, diikuti oleh Tier 3 sebesar 2279.63, sedangkan Tier 1 memiliki rata-rata sales terendah sebesar 1876.91. Hal ini menunjukkan bahwa outlet pada lokasi Tier 2 memiliki performa penjualan rata-rata paling tinggi dibandingkan lokasi lainnya. Sehingga bisa memprioritaskan kepada Location type Tier 2 untuk menaikan penjualan

CHOOSE FRESH CHOOSE LOCAL

VISUALIZATION OUTPUT

```
bigmart_copy.groupby("Outlet_Location_Type")["Item_Outlet_Sales"].agg(["sum"]).rename(
    columns={"sum": "Total_Location_Sales"}
).sort_values(
    by="Total_Location_Sales",
    ascending=False
).round(2)
```

Outlet_Location_Type	Total_Location_Sales
Tier 3	7636752.63
Tier 2	6472313.71
Tier 1	4482059.07



Dari perbandingan 2 chart tersebut kita bisa mengambil 2 insight:

1.Jika kita ingin melihat performa rata-rata, maka Tier 2 lah yang memberikan performa tinggi

2.Jika kita ingin melihat tier mana yang memberikan revenue tinggi maka Tier 3 lah yang memberikan revenue yang paling tinggi

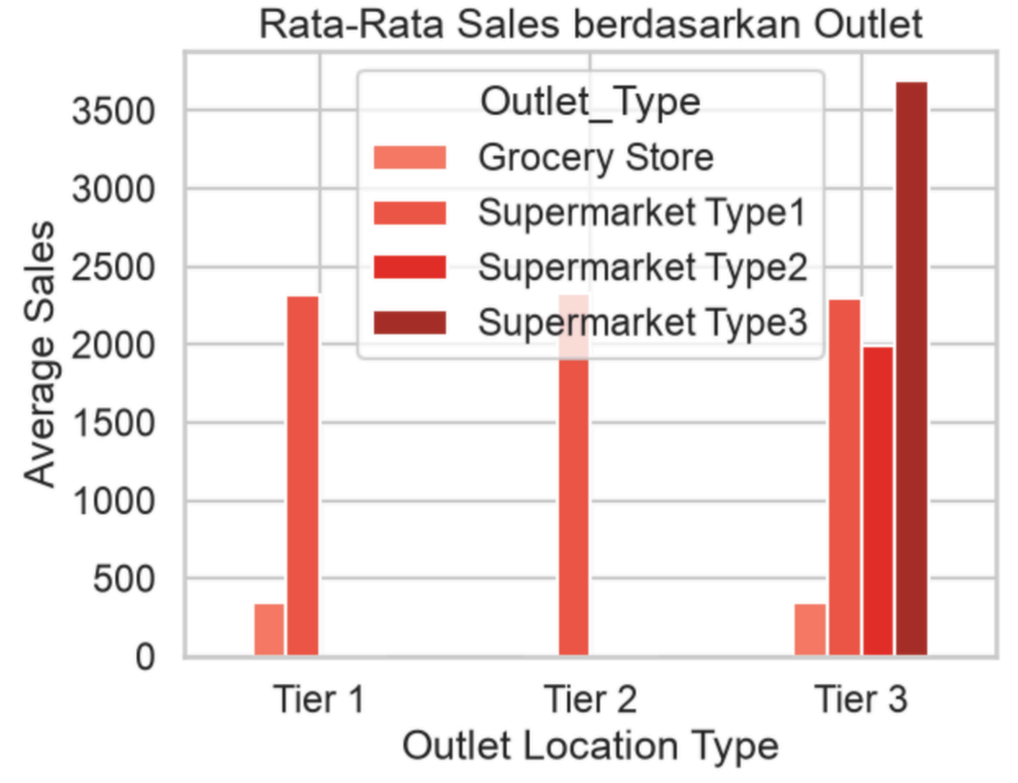
CHOOSE FRESH CHOOSE LOCAL

VISUALIZATION OUTPUT

```
crosstab_outlet = pd.crosstab(
    bigmart_copy["Outlet_Location_Type"],
    bigmart_copy["Outlet_Type"],
    values=bigmart_copy["Item_Outlet_Sales"],
    aggfunc="mean"
)

crosstab_outlet
```

Outlet_Type	Grocery Store	Supermarket Type1	Supermarket Type2	Supermarket Type3
Outlet_Location_Type				
Tier 1	340.329723	2313.099451	NaN	NaN
Tier 2	NaN	2323.990559	NaN	NaN
Tier 3	339.351662	2298.995256	1995.498739	3694.038558



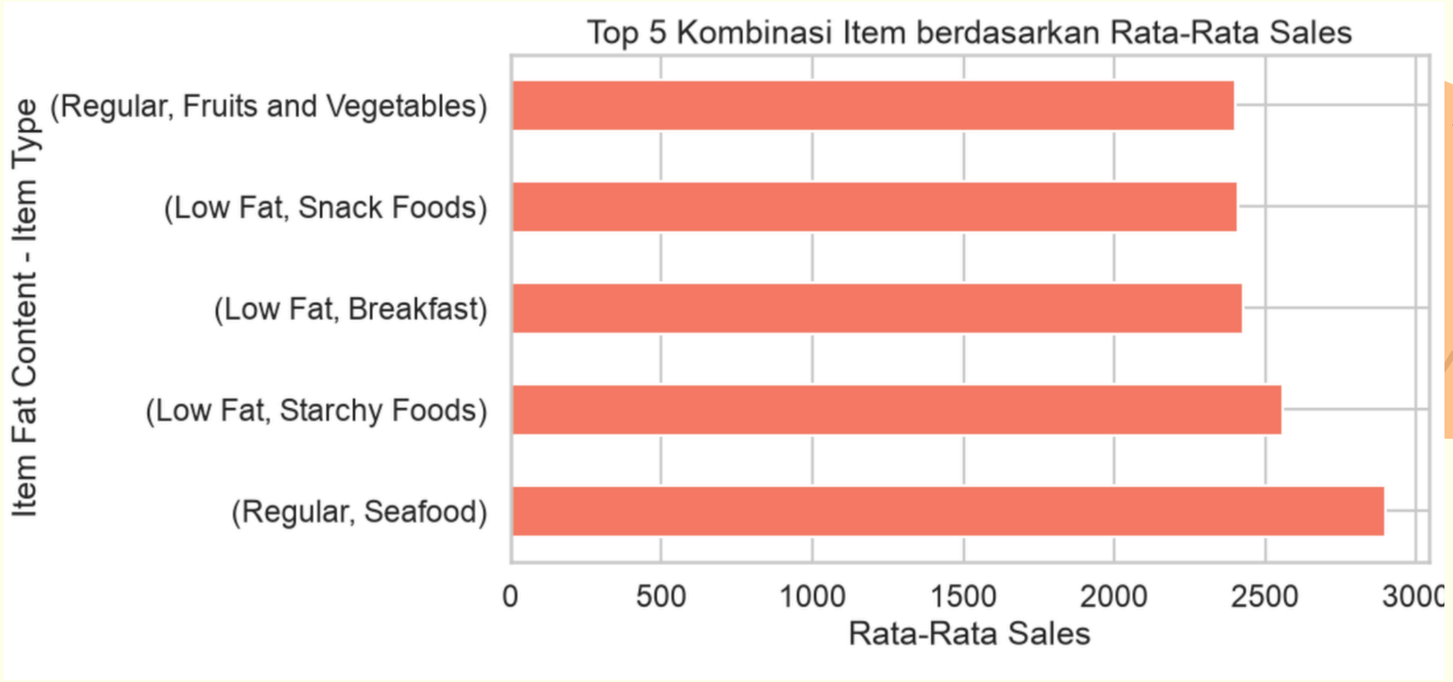
Supermarket Tipe 1 cenderung menunjukkan penjualan yang konsisten di berbagai tipe lokasi, sementara Supermarket Tipe 3 (Tier 3) menghasilkan penjualan terbaik. Oleh karena itu, strategi pengembangan jenis outlet sebaiknya mempertimbangkan kombinasi antara jenis outlet dan karakteristik lokasi.

CHOOSE FRESH CHOOSE LOCAL

VISUALIZATION OUTPUT

```
bigmart_copy.groupby(
    ["Item_Fat_Content", "Item_Type"]
)["Item_Outlet_Sales"].agg(["mean"]).rename(
    columns={"mean": "Rata_Rata_Sales"}
).sort_values(
    by="Rata_Rata_Sales",
    ascending=False
).head(5)
```

Item_Fat_Content	Item_Type	Rata_Rata_Sales
Regular	Seafood	2899.263089
Low Fat	Starchy Foods	2558.425815
	Breakfast	2425.411966
	Snack Foods	2411.978843
Regular	Fruits and Vegetables	2400.571761



Seafood memiliki performa penjualan tertinggi sebesar 2899.26, sedangkan fruits and vegetables memiliki rata-rata sales terendah dari 5 kombinasi yang dianalisis, yaitu 2400.57

Kategori Regular maupun Low Fat tidak konsisten menghasilkan sales yang lebih tinggi, sehingga Item_Type menjadi faktor yang lebih mempengaruhi dalam perbedaan penjualan.

Fokus terhadap Item_Type khusus nya seafood jika ingin memperoleh hasil sales yang maksimal

CHOOSE FRESH CHOOSE LOCAL

```
crosstab_sales = pd.crosstab(
    bigmart_copy["Item_Fat_Content"],
    bigmart_copy["Item_Type"],
    values=bigmart_copy["Item_Outlet_Sales"],
    aggfunc="mean"
)

crosstab_sales
```

Item_Type	Baking Goods	Breads	Breakfast	Canned	Dairy	Frozen Foods	Fruits and Vegetables	Hard Drinks
Item_Fat_Content								
Low Fat	1764.509636	2183.434031	2425.411966	2208.714377	2145.174151	2117.535472	2182.405740	2139.221622
Regular	2147.340665	2230.238058	1925.464652	2243.441202	2370.875970	2149.861640	2400.571761	NaN

Health and Hygiene	Household	Meat	Others	Seafood	Snack Foods	Soft Drinks	Starchy Foods
2010.000265	2258.7843	2035.616920	1926.139702	1907.786919	2411.978843	2035.452072	2558.425815
NaN	NaN	2241.218571	NaN	2899.263089	2093.891196	1854.065451	2145.611115

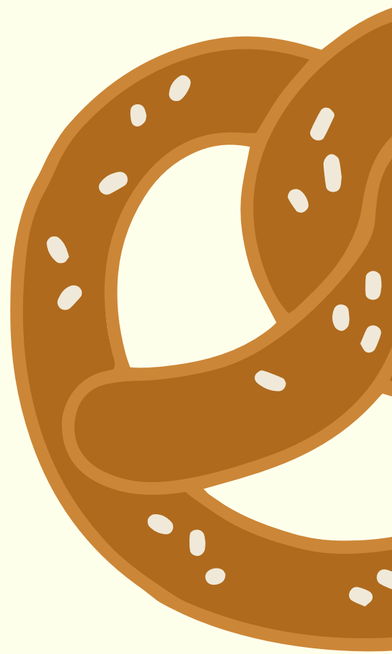
Perbedaan Item_Fat_Content tidak menunjukkan pola yang konsisten terhadap penjualan. Produk regular memiliki penjualan lebih tinggi pada beberapa kategori seperti Seafood dan Fruits and Vegetables, sementara low fat lebih tinggi pada kategori seperti Breakfast dan Starchy Foods. Oleh karena itu, strategi penjualan sebaiknya lebih berfokus pada Item_Type daripada hanya mengandalkan kategori Item_Fat_Content.

CHOOSE FRESH CHOOSE LOCAL

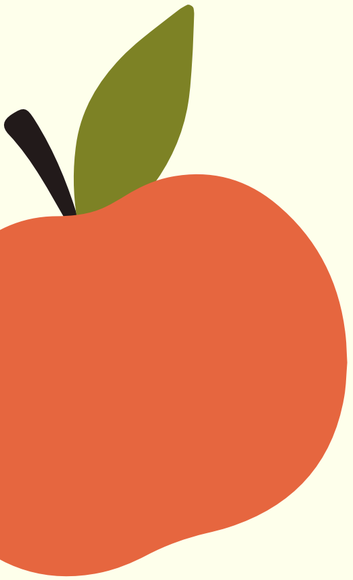
CONCLUSION AND RECOMMENDATIONS



1. Menawarkan promo seperti bundling atau diskon pada produk Household untuk meningkatkan daya tarik pembelian, karena kategori ini memiliki rata-rata MRP paling tinggi tetapi untuk rata-rata sales belum menjadi yang tertinggi
2. Prioritaskan wilayah dengan sales tinggi di outlet Tier 2 karena memiliki performa yang bagus, juga menjaga stok produk pada outlet Tier 3 dikarenakan revenue terbesar ada pada tier tersebut
3. Prioritaskan stok pada Item_Type dengan sales tinggi agar tidak terjadi kekurangan produk, dan juga Tingkatkan promosi pada Item_Type yang terbukti memiliki permintaan tinggi



CHOOSE FRESH CHOOSE LOCAL



THANK YOU



MINI PROJECT 2026 MINI PROJECT